

Segmentación y Clasificación Automática de Malezas mediante Procesamiento Digital de Imágenes y Visión por Computador sobre el Dataset OPPD

Castaño Giraldo, Mariana – Cadena Trujillo, Linda Liceth - Pineda Pedraza, Juan Jose

Escuela de Ciencias Aplicadas e Ingeniería, Universidad EAFIT, Medellín, Colombia

Ingeniería agronómica, EAFIT, Medellín, Colombia, mcastanog2@eafit.edu.co

Ingeniería agronómica, EAFIT, Medellín, Colombia, llcadenat@eafit.edu.co

Ingeniería agronómica, EAFIT, Medellín, Colombia, jjpinedap1@eafit.edu.co

1. Abstract

Weeds pose a major threat to global agriculture, and traditional identification is inefficient. This study presents an interpretable computer vision pipeline for automated weed segmentation and classification using an Open Plant Phenotyping Database (OPPD) subset of 98 field images across 52 species. The methodology involves color space conversion, comparative segmentation, morphological refinement via PlantCV, edge detection, and feature extraction. Classifying the extracted data with Gaussian Naïve Bayes demonstrated that Otsu thresholding on the LAB a* channel excels in plant-soil discrimination. Furthermore, color features enable species-level classification, though performance is affected by class imbalance and visual similarity, proving classical computer vision to be a viable, cost-effective tool for precision agriculture.

2. Resumen

Las malezas representan una amenaza crítica para la agricultura, y su identificación manual resulta ineficiente. Este trabajo propone una cadena de procesamiento interpretable de visión por computador para la segmentación y clasificación automática de malezas, utilizando un subconjunto del OPPD con 98 imágenes de campo y 52 especies. La metodología abarca la conversión de espacios de color,

evaluación de métodos de segmentación, refinamiento morfológico con PlantCV, detección de bordes y extracción de características. Al emplear Gaussian Naïve Bayes, los resultados confirmaron que el umbral de Otsu sobre el canal a* del espacio LAB optimiza la separación planta-suelo. Asimismo, las características cromáticas permiten identificar especies, aunque el desempeño se ve limitado por el desbalanceo de clases, demostrando la viabilidad y el bajo costo computacional de la visión clásica para la agricultura de precisión.

3. Introducción

Las malezas representan una amenaza crítica para la productividad agrícola global, reduciendo los rendimientos desde un 10% hasta un 50 % en casos severos, lo que afecta directamente a la seguridad alimentaria. El manejo tradicional, basado en inspecciones manuales o la aplicación indiscriminada de herbicidas, resulta ineficiente e insostenible, ya que incrementa los costos de producción, contamina los ecosistemas y fomenta la resistencia de las especies nocivas

La visión por computador ofrece una vía prometedora para automatizar la detección e identificación de malezas directamente a partir de imágenes digitales del cultivo. El procesamiento digital de imágenes permite construir pipelines interpretables, eficientes computacionalmente y adaptables a condiciones de campo con recursos moderados.

En este contexto, el trabajo tiene como objetivo desarrollar y evaluar un pipeline completo de visión por computador para la segmentación automática de vegetación y la clasificación de especies de malezas a partir de imágenes RGB de campo, utilizando el subconjunto de muestra del OPPD. (Pamplona Beron et al., 2020; Farkhani et al., 2021).

4. Metodología

4.1. Exploración del dataset

La primera etapa del pipeline consistió en la lectura y estructuración de los 97 archivos de anotación JSON del subconjunto OPPD. Para cada archivo se extrajo la información de cada bounding box, clase EPPO, coordenadas, dimensiones y área en píxeles. Esta información se consolidó en un Dataframe de 3.894 filas. El análisis estadístico permitió caracterizar la densidad de anotaciones por imagen la cual tuvo una mediana de 40 objetos, el rango de áreas de bounding boxes y la evolución temporal de capturas por trial.

4.2. Conversión de Espacios de Color

Para cada imagen se realizó la conversión desde RGB hacia HSV, LAB y escala de grises, utilizando scikit-image. El espacio HSV desacopla el matiz de la luminosidad, otorgando robustez ante cambios de iluminación, mientras que el espacio LAB ofrece el canal a (oposición verde-rojo) como discriminador natural entre vegetación clorofílica y suelo (Pamplona Beron et al., 2020).

4.3. Segmentación por Umbralización

Se evaluaron tres métodos para separar la vegetación del fondo: umbralización manual (0.5) sobre el canal G de RGB, el algoritmo de Otsu sobre el canal H de HSV, y Otsu sobre el canal a de LAB. Este último se identificó como el más efectivo, ya que los valores negativos de a corresponden a tonos verdes y los positivos a tonos ocre, separando naturalmente la planta del suelo.

4.4. Refinamiento Morfológico

Para corregir la fragmentación y los huecos en las máscaras binarias, se aplicó una secuencia morfológica: una operación de cierre (7×7 píxeles) para conectar fragmentos, relleno de huecos internos con `scipy.ndimage`, y eliminación de componentes conexas menores a 200 píxeles utilizando PlantCV (Fahlgren et al., 2015). Esto produjo máscaras más compactas y morfológicamente consistentes, reduciendo la tasa de falsos positivos en la segmentación final.




Figura 1. Aplicación de operaciones morfológicas sobre la máscara a de LAB

4.5. Construcción del Dataset Tabular

Para cada bounding box en las 15 imágenes procesadas, se extrajo el crop correspondiente, se redimensionó a 64×64 píxeles y se convirtió a los espacios HSV y LAB. Sobre cada crop se calcularon la media y la desviación estándar de cada canal en los tres espacios (RGB, HSV, LAB), generando un vector de 18 características numéricas por instancia. También se sumaron los descriptores de forma de PlantCV (área, perímetro, relación de aspecto y compacidad). El dataset resultante se filtro para conservar únicamente las clases con al menos 20 instancias.

4.6. Clasificación con Gaussian Naïve Bayes

Se implementó un modelo Gaussian Naïve Bayes (GNB) debido a su eficiencia e interpretabilidad en espacios de características de tamaño moderado. El dataset se dividió en entrenamiento (80 %) y prueba (20 %), evaluando el desempeño mediante exactitud global, F1-score y matriz de confusión.

5. Resultados

5.1.

Se confirmó un marcado desbalanceo: las tres especies más frecuentes concentraron más del 60 % de las anotaciones. Las áreas de los bounding boxes mostraron alta varianza, desde plántulas ($< 1.000 \text{ px}^2$) hasta plantas adultas ($> 500.000 \text{ px}^2$), evidenciando una heterogeneidad morfológica significativa y variaciones de abundancia entre los trials (Farkhani et al., 2021).

5.2.

La umbralización sobre el canal G mostró sensibilidad excesiva a la iluminación, clasificando suelo reflectante como planta. Otsu sobre el canal H mejoró la consistencia, pero fragmentó hojas senescentes. Finalmente, Otsu sobre el canal a de LAB produjo las máscaras más coherentes y robustas frente al suelo logrando una separación limpia de la clorofila.




Figura 2. Visualización de los diferentes métodos de umbralización




Figura 3. Validación de contorno con bordes Canny

5.3.

El GNB fue entrenado sobre el vector de 18 características de color extraído de los crops. En donde las especies con mayor número de muestras como *Chenopodium album* (CHEAL) y *Fumaria*

officinalis (FUMOF) alcanzaron valores de F1-score más altos, mientras que las clases minoritarias presentaron mayor confusión. Los errores más frecuentes ocurrieron entre especies con morfología foliar y tonalidades similares, evidenciando las limitaciones de clasificar basándose en estadísticas globales de color frente a una alta variabilidad intra-clase fenológica.

6. Discusión

El pipeline desarrollado demuestra que métodos clásicos de visión por computador son capaces de extraer información discriminante de imágenes agrícolas de campo sin tener que recurrir a herramientas de aprendizaje profundo. En donde se destaca por su alta interpretabilidad.

El hallazgo más relevante es la superioridad del canal *a* del espacio LAB. Que diferencia del canal *G* de RGB o del canal *H* de HSV, encapsula directamente la oposición entre clorofila y pigmentos del suelo, resultando en máscaras de mayor calidad con menor dependencia de parámetros manuales.

El desbalanceo de clases es el principal factor limitante del sistema. Con pocas instancias disponibles para las clases minoritarias, el clasificador tiende a favorecer las clases mayoritarias, generando sesgos sistemáticos.

7. Conclusión

Este trabajo presentó un pipeline completo de visión por computador para la segmentación y clasificación de malezas agrícolas sobre el subconjunto de datos OPPD, integrando exploración estadística, análisis multiespacio de color, umbralización, refinamiento morfológico, detección de bordes y clasificación probabilística.

El análisis comparativo de espacios de color demostró la superioridad del canal *a* del espacio LAB para la segmentación planta-suelo. El pipeline morfológico resultó efectivo para consolidar máscaras ruidosas. El desbalanceo de clases, solapamiento inter-especie y restricciones del GNB constituyen oportunidades concretas de mejora mediante características de textura, clasificadores no lineales y técnicas de aumento de datos.

El trabajo sienta las bases para un sistema de soporte a la decisión, el cual integrado con cámaras en equipos de campo, podría guiar a la aplicación selectiva de herbicidas por zonas de infestación, reduciendo el uso de agroquímicos y sus efectos ambientales adversos. La visión por computador,

interpretable y de bajo costo computacional, es una herramienta de alto potencial para la modernización de la agricultura de precisión.

8. Bibliografía

Fahlgren, N., Feldman, M., Gehan, M. A., Wilson, M. S., Shyu, C., Bryant, D. W., Hill, S. T., McEntee, C. J., Warnasooriya, S. N., Kumar, I., Ficor, T., Turnipseed, S., Gilbert, K. B., Brutnell, T. P., Carrington, J. C., Mockler, T. C., & Baxter, I. (2015). A versatile phenotyping system and analytics platform reveals diverse temporal responses to water availability in *Setaria*. *Molecular Plant*, 8(10), 1520–1535. <https://www.cell.com/molecular-plant/fulltext/>

Pamplona Beron, L. E., Calvo Salcedo, A. F., & Bejarano Martínez, A. (2020). Detection of foliar diseases using image processing techniques. *Revista Ceres*, 67(2), 100-110. <https://www.scielo.br/j/rceres/a/lang>

Farkhani, S., Skovsen, S. K., Dyrmann, M., Jørgensen, R. N., & Karstoft, H. (2021). Weed classification using explainable multi-resolution slot attention. *Sensors*, 21(20), 6705. <https://www.mdpi.com/1424-8220/21/20/6705>

Bhagya Lakshmi, Y., Rakesh, Y., Subramanyam, S., Hari Priya, T., & Anusha Reddy, G. (2025). Smart agriculture: Machine learning and deep learning for advanced weed detection and crop quality enhancement. *International Journal of Computational Learning & Intelligence*, 4(3), 529-540. https://zenodo.org/records/15210829?preview_file=v4i3p6.pdf